

Modelo N4 de trazabilidad cognitiva para la enseñanza universitaria de programación con asistentes de IA generativa: formalización conceptual y propuesta de validación empírica

Alberto Cortez (1,2) y Ana Garis (1,2)

(1) Universidad Tecnológica Nacional, Facultad Regional Mendoza, Argentina

(2) Doctorado en Ciencias de la Computación, Universidad Nacional de San Luis, Argentina

{albertocortez, anagaris}@frm.utn.edu.ar

Resumen

La irrupción de los asistentes de IA generativa en la formación universitaria de programación ha invalidado la premisa evaluativa tradicional según la cual el código entregado por el estudiante constituye evidencia confiable de su aprendizaje. Las respuestas reactivas habituales — prohibición o detección forense ex-post— resultan estructuralmente insuficientes porque operan sobre el producto y no sobre el proceso cognitivo del estudiante. Este trabajo presenta el Modelo N4 de Trazabilidad Cognitiva, marco analítico que organiza la observación del proceso de resolución en cuatro niveles articulados — comprensión del problema, estrategia de resolución, validación de la solución e interacción con IA— tratando este último como nivel autónomo y no como variable contextual subsidiaria. El modelo se operacionaliza mediante una ontología de eventos observables persistidos en un Cognitive Trace Record, sobre los cuales un Clasificador N4 explícito calcula cinco coherencias agregadas y asigna a cada episodio cerrado una de tres categorías de apropiación cognitiva: delegación pasiva, apropiación superficial o apropiación reflexiva. El paper formaliza el modelo, articula los tres órdenes epistemológicos involucrados (eventos observables, indicadores derivados, constructos sintéticos), y presenta una propuesta metodológica de validación basada en un diseño cuasi-experimental con tres hipótesis contrastables y un protocolo dual de fiabilidad intercodificador con $\text{target } \kappa \geq 0,70$ conforme a la convención de Landis y Koch [12], estructurado en dos componentes paralelos: validación del etiquetador sobre 200 eventos estratificados (50 por nivel cognitivo N1-N4) y validación del árbol de decisión sobre 50 episodios cerrados distribuidos entre las tres categorías de apropiación. Se discute explícitamente el confound intervención-medición como limitación estructural del enfoque y se formula la agenda de validación confirmatoria.

Palabras clave: trazabilidad cognitiva, IA generativa, enseñanza de programación, modelo N4, evaluación auténtica, kappa de Cohen, evidence-centered design, cognición distribuida.

1. Introducción

La incorporación masiva de asistentes de IA generativa al trabajo cotidiano de estudiantes de programación universitaria, fenómeno consolidado entre 2022 y 2026 con la disponibilidad pública amplia de modelos como ChatGPT, Claude, Gemini y GitHub Copilot, ha modificado en pocos años las prácticas formativas y evaluativas de las cátedras del campo. La pregunta que el cuerpo docente enfrenta no admite dilación: si el código entregado deja de ser evidencia confiable del razonamiento del estudiante, ¿cómo evaluamos lo que aprendió?

El problema admite una formulación en tres dimensiones articuladas. En su dimensión evaluativa, la evidencia empírica reciente [4, 9, 13] documenta que los modelos generativos contemporáneos producen código funcional que supera el desempeño promedio estudiantil en CS1 y CS2, con la consecuencia directa de que el código entregado pierde su valor como base inferencial de un proceso cognitivo no observado. En su dimensión epistemológica, la crisis trasciende la mera validez de los instrumentos e interpela los fundamentos sobre los que se construyen las inferencias acerca del aprendizaje [11, 14]: la cadena evaluativa que iba desde el código (observable) hacia el aprendizaje (constructo inferido) se ha quebrado por la mediación opaca de un agente cuya contribución no queda registrada. En su dimensión pedagógica, el problema concierne a la formación de programadores en un ecosistema profesional que ha incorporado a la IA generativa como pieza estable del flujo de trabajo: una formación que la prohíbe segrega del contexto profesional contemporáneo, una formación que la admite sin más corre el riesgo de no formar el razonamiento autónomo que la disciplina requiere.

La especificidad estructural del dominio programación agrava el problema. A diferencia de la escritura académica o del diseño, donde la voz autoral o la sensibilidad situacional dejan marcas estilísticas que un lector experto puede identificar, en programación la corrección funcional es binaria y verificable automáticamente: un fragmento de código que ordena una lista es indistinguible de cualquier otro fragmento que produzca el mismo resultado para las mismas entradas, independientemente de quién lo haya

producido. Esta indistinguibilidad funcional no es una limitación temporal de los detectores sino una propiedad estructural del dominio.

Una tercera vía, todavía minoritariamente explorada en la práctica argentina, propone instrumentar el proceso cognitivo del estudiante durante la sesión misma de trabajo y producir un registro auditable de sus acciones cognitivas observables, de modo que la cátedra pueda razonar sobre el proceso y no sólo sobre el producto [3, 18]. Esta vía es metodológicamente prometedora pero exige un aparato conceptual que no se reduce a la suma de tecnología disponible: requiere un modelo del proceso cognitivo que permita interpretar los registros, criterios evaluativos que no dependan de la corrección del artefacto, y un protocolo de validación que sostenga la confiabilidad de las inferencias.

El presente trabajo presenta el Modelo N4 de Trazabilidad Cognitiva como respuesta articulada a esta exigencia. El modelo se materializa en el proyecto AI-Native N4, una plataforma de software desplegada en el piloto UNSL 2026 que opera sobre una arquitectura de servicios distribuida con propiedades de auditabilidad criptográfica; el presente paper se enfoca en la formalización conceptual del modelo, mientras que las decisiones de despliegue y los detalles de implementación de la plataforma quedan documentados de manera canónica en los Architectural Decision Records del repositorio del proyecto, accesibles al lector interesado en la articulación entre formalización y operación. La sección 2 posiciona el aporte respecto del estado del arte. La sección 3 desarrolla el marco teórico que sustenta las decisiones epistemológicas del modelo. La sección 4 formaliza el modelo en sus cuatro niveles, los tres tipos de apropiación de la IA, las tres dimensiones de coherencia estructural y un ejemplo canónico ilustrativo. La sección 5 describe la operacionalización mediante el Cognitive Trace Record y el Clasificador N4. La sección 6 presenta el diseño cuasi-experimental para la validación empírica con sus tres hipótesis contrastables y su confound declarado. La sección 7 formula el protocolo de fiabilidad intercodificador con kappa de Cohen y discute consideraciones de equidad. La sección 8 reporta hallazgos cualitativos parciales, el estado del sistema instrumental al cierre y la agenda confirmatoria. La sección 9 discute el posicionamiento del modelo frente a la literatura reciente. La sección 10 cierra con conclusiones.

2. Antecedentes y posicionamiento

El campo de la enseñanza de programación con IA generativa ha producido en los últimos tres años una literatura en expansión exponencial. Cinco revisiones recientes cubren el campo con énfasis distintos, sin que

ninguna de ellas articule simultáneamente las dimensiones de gobernanza institucional, instrumentación del proceso cognitivo y validación de la autoría que el presente modelo propone. Elnaffar et al. [8] reportan una revisión sistemática de 58 estudios sobre LLM en educación universitaria con foco general. Reihanian et al. [16] revisan personalización habilitada por IA generativa en CS education con énfasis en métricas de desempeño. Bernstein et al. [2] documentan empíricamente el fenómeno de daños cognitivos (cognitive offloading, metacognitive laziness) en estudiantes universitarios expuestos a asistentes de IA, identificando 224 estudios de un corpus inicial de 1677. Prather et al. [15] presentan un análisis cualitativo de las nuevas dimensiones del aprendizaje de programación en contextos mediados por IA. Una revisión bibliométrica reciente sobre metacognición en STEM [19] identifica el cognitive offloading como constructo emergente sin instrumento estandarizado de medición.

La literatura argentina y latinoamericana 2025 documenta empíricamente la situación regional con varios trabajos que constituyen antecedentes específicos del presente modelo. Paez et al. [12] reportan, en un estudio preliminar, el uso de la inteligencia artificial en la enseñanza de la programación en universidades argentinas, encontrando adopción mayoritaria sin orientación pedagógica institucional explícita. Oviedo et al. [10] aportan la perspectiva estudiantil mediante un análisis basado en el Modelo 3P de Biggs en la Universidad Nacional de San Juan, mostrando coexistencia entre alta motivación de uso y autopercepción de riesgo cognitivo en los estudiantes. Garrido y Neil [9] presentan un mapeo sistemático de la literatura sobre el impacto de la IA en la experiencia de aprendizaje y las prácticas evaluativas universitarias, que documenta un cambio de paradigma en las metodologías de enseñanza y evaluación e identifica desafíos específicos para la integración de estas herramientas. Estos trabajos dialogan con el presente modelo en tres puntos específicos: confirman empíricamente la existencia del problema en la población argentina, identifican el gap evaluativo que el modelo propone abordar, y aportan el contexto institucional sobre el que el modelo se valida.

El aporte distintivo del Modelo N4 respecto de las cinco revisiones internacionales y los cuatro antecedentes regionales es triple. Primero, ofrece un aparato conceptual que trata la interacción del estudiante con la IA como dimensión cognitiva autónoma con sus operaciones distintivas, en lugar de subsumirla bajo categorías genéricas de uso de herramientas. Segundo, articula tres tipos observacionalmente distinguibles de apropiación de la IA (delegación pasiva, apropiación superficial, apropiación reflexiva) que no son etiquetas morales sobre el estudiante sino caracterizaciones de patrones de uso del asistente. Tercero, propone un criterio evaluativo

multidimensional —la coherencia estructural— que opera sobre el proceso y no sobre el producto, y se operacionaliza mediante indicadores reproducibles bit-a-bit que el cuerpo docente puede consultar y contrastar con su propio juicio profesional.

3. Marco teórico

Cuatro tradiciones teóricas convergentes sustentan las decisiones epistemológicas del Modelo N4. La tesis de la cognición distribuida [10] sostiene que la cognición humana no se localiza exclusivamente en el cerebro individual sino que se distribuye a través de artefactos, agentes y representaciones externas. Aplicada al uso de asistentes de IA en programación, la tesis sustenta la decisión de incluir N4 como nivel autónomo: la interacción con el asistente no es accesoria al proceso cognitivo sino potencialmente constitutiva del mismo. La tesis de la mente extendida [4] complementa este marco al argumentar que cuando un sistema externo opera con suficiente acoplamiento funcional con el agente humano, puede considerarse parte de su sistema cognitivo. La consecuencia metodológica es que la observación del proceso cognitivo no debe descartar la interacción con el asistente como distorsión a controlar sino integrarla como dimensión a observar.

La tradición de génesis instrumental [20] aporta el reconocimiento de la variabilidad inter-sujeto en la apropiación de los instrumentos cognitivos: distintos estudiantes desarrollan distintos esquemas de uso de la misma herramienta, y esta variabilidad es pedagógicamente productiva. La distinción entre delegación pasiva, apropiación superficial y apropiación reflexiva que el modelo propone se inscribe directamente en este marco: caracteriza tres regímenes distintos de apropiación instrumental observables sobre los registros del proceso. La cuarta tradición, evidence-centered design [Mislevy, Steinberg y Almond, 2003; Pellegrino, Chudowsky y Glaser, 2001], aporta el aparato conceptual para articular cadenas inferenciales rigurosas desde evidencia observable hacia constructos teóricos. La crisis evaluativa contemporánea es, en su núcleo, una crisis del eslabón medio de la cadena evidence-centered: lo que era evidencia (el código) ya no sostiene la inferencia hacia el aprendizaje. Reconstruir la cadena exige producir nueva evidencia desde la observación del proceso, y articularla con los constructos teóricos mediante reglas explícitas de codificación.

Sobre estas cuatro tradiciones se asienta una decisión epistemológica fundacional: el modelo distingue entre constructos contrastables empíricamente y constructos sintéticos que operan como horizonte interpretativo. Las hipótesis del trabajo (sección 6) se formulan en términos de

indicadores derivados susceptibles de contrastación. Los constructos sintéticos —calidad epistémica, apropiación reflexiva en sentido fuerte, coherencia estructural multidimensional— operan como horizontes de lectura que orientan la interpretación pedagógica de los resultados sin pretender ser variables medibles directamente.

Una asimetría entre el marco teórico declarado y la operacionalización efectiva del Modelo N4 merece tematización explícita. Las tesis de cognición distribuida [10] y mente extendida [4] sostienen que el sistema cognitivo relevante para el aprendizaje en interacción con asistentes de IA no es el estudiante individual considerado en aislamiento sino el sistema acoplado estudiante-tutor-IDE-tests-enunciado. La operacionalización empírica del Modelo N4 mediante las cinco coherencias agregadas mide, sin embargo, al estudiante como nodo del sistema; la contribución cognitiva específica del tutor (calidad del andamiaje socrático, complejidad pedagógica del prompt vigente, profundidad de las respuestas) no se desagrega operacionalmente de la trayectoria estudiantil en la versión actual del clasificador. La consecuencia metodológica es que las inferencias del clasificador sobre apropiación se realizan sobre un nodo del sistema distribuido y no sobre el sistema entero. Esta asimetría no invalida los indicadores —el estudiante es el componente que cambia y que el modelo se propone evaluar formativamente—, pero exige declarar el alcance de las afirmaciones: el sistema mide patrones de uso del asistente por el estudiante, no propiedades emergentes del sistema cognitivo distribuido completo. La operacionalización de indicadores del sistema extendido (caracterización de la contribución del tutor por episodio, separación de la contribución del IDE, latencias clave del bucle de retroalimentación) constituye agenda de investigación futura sobre cognición distribuida instrumentada, articulada con la agenda confirmatoria de la Sección 8.

4. El Modelo N4: formalización

4.1 Los cuatro niveles del modelo


El Modelo N4 organiza la observación del proceso de resolución de problemas de programación en cuatro niveles analíticos articulados. El Nivel 1 (Comprensión del problema) captura las acciones orientadas a la comprensión del problema antes y durante el desarrollo de una solución: lectura del enunciado, identificación de entradas y salidas esperadas, análisis de casos límite, reformulación del problema en términos propios. El Nivel 2 (Estrategia de resolución) captura las acciones orientadas al diseño de la estrategia: descomposición en subproblemas, elección de estructuras de datos, selección de algoritmos, articulación de invariantes. El Nivel 3 (Validación de la solución) captura las acciones de verificación contra casos de prueba,

análisis de cobertura, depuración, razonamiento sobre complejidad. El Nivel 4 (Interacción con IA) captura las acciones del estudiante en su interacción con el asistente: formulación de prompts, lectura crítica de respuestas, reformulación tras respuestas insatisfactorias, verificación crítica de propuestas, apropiación argumentada.

La decisión epistemológica de tratar la dimensión N4 como nivel analítico autónomo, y no como subsidiaria de los anteriores, constituye la contribución más distintiva del modelo. Tres consideraciones sustentan esta decisión. Primera, si se adoptan los marcos de cognición distribuida y mente extendida, la interacción con IA no es accesoria al proceso cognitivo sino potencialmente constitutiva. Tratarla como subsidiaria oscurecería su especificidad. Segunda, la interacción con IA tiene gramáticas propias — formulación de prompts útiles, evaluación crítica de respuestas, gestión iterativa de contextos— que no se

reducen a las gramáticas de comprensión, estrategia o validación. Tercera, los tipos de apropiación del asistente son distinguibles analíticamente solo a nivel agregado, lo cual exige un nivel analítico específico que tenga ese objeto como foco propio. La Fig. 1 representa la arquitectura conceptual del modelo: tres niveles ordenados en el eje temporal del proceso de resolución (N1, N2, N3) más una dimensión paralela (N4) que atraviesa los tres niveles anteriores.

Figura 1. Los cuatro niveles del Modelo N4. N1, N2 y N3 se ordenan en el eje temporal del proceso de resolución con retroalimentaciones desde N3. N4 (Interacción con IA) opera como dimensión paralela que atraviesa los tres niveles anteriores.



Los cuatro niveles no son independientes. En una trayectoria típica, N1 precede a N2, que a su vez precede a una primera producción evaluada mediante N3. Los resultados de N3 retroalimentan a N1 (comprensión revisada) o a N2 (reconsideración de la estrategia), produciendo nuevas iteraciones. N4 atraviesa los otros tres: la interacción con el asistente puede orientarse a clarificar la comprensión del problema, a discutir estrategias alternativas o a verificar críticamente la solución, y las apropiaciones resultantes se integran en cualquiera de los niveles. Esta arquitectura de niveles entrelazados se distingue explícitamente de las jerarquías taxonómicas clásicas como la revisión de Bloom por Anderson y Krathwohl o la taxonomía SOLO de Biggs y Collis: no hay una jerarquía cognitiva entre los niveles. N3 no es necesariamente “más alto” que N1, ni N4 “más bajo” que N2. Los niveles son dimensiones analíticas paralelas del proceso, no etapas jerárquicas del desarrollo cognitivo. Esta decisión teórica se respeta de manera literal en el sistema instrumental que materializa el modelo: el etiquetador del Cognitive Trace Record no asigna ordinalidad entre niveles, y un mismo evento puede pertenecer a N4 sin que eso implique paso previo por N1, N2 o N3.

4.2 Operacionalización en eventos observables

Cada uno de los cuatro niveles se operacionaliza mediante un catálogo de eventos observables registrables por la instrumentación del sistema. La Tabla 1 presenta la ontología de eventos organizada por nivel.

Tabla 1. Ontología de eventos observables del Modelo N4 por nivel.

Nivel	Eventos observables registrables
N1	Lectura del enunciado, anotaciones tempranas ($\leq$ 120s desde apertura), reformulación del problema, ejemplos elaborados, preguntas clarificadoras al tutor sobre el enunciado
N2	Edición de código tipeado, pseudocódigo en comentarios, selección de estructura de datos, enunciado de invariante, descomposición explícita en funciones
N3	Ejecución del código, ejecución de tests con conteo de pruebas pasadas/fallidas, análisis de salidas, depuración con prints, revisión de invariante
N4	Prompt enviado al tutor, respuesta recibida, reformulación de prompt, anotación post-respuesta ($\leq$ 60s), código pegado desde el tutor, intento adverso detectado

Dos overrides condicionales operan sobre el mapeo base. Cuando una edición de código tiene origen `pasted_external` (código pegado desde fuente externa) o

`copied_from_tutor` (código incorporado desde el propio tutor), su etiqueta cambia de N2 a N4 por tratarse de apropiación de código de origen interactivo y no de elaboración propia. Cuando una anotación se produce dentro de los 120 segundos posteriores a la apertura del episodio, se etiqueta como N1 por tratarse plausiblemente de lectura del enunciado; si se produce dentro de los 60 segundos posteriores a una respuesta del tutor, se etiqueta como N4 por apropiación reflexiva. Estas constantes de ventana han sido sometidas a análisis de sensibilidad sobre 2000 episodios sintéticos generados con semilla determinista, mostrando robustez de las decisiones dentro del rango operativo. La función pura de mapeo evento-a-nivel está versionada en el sistema instrumental mediante una constante de versión que permite reanálisis reproducibles ante cualquier modificación posterior del catálogo.

4.3 Tres órdenes epistemológicos de los constructos

La operacionalización del modelo procede mediante la distinción explícita de tres órdenes epistemológicos de los constructos involucrados. Esta distinción es importante para evitar confusiones entre niveles de análisis y para situar adecuadamente las afirmaciones del trabajo. La Fig. 2 representa la articulación de los tres órdenes con las hipótesis contrastables y el marco interpretativo.




Figura 2. Tres órdenes epistemológicos de los constructos del Modelo N4. Las hipótesis H1–H3 se formulan sobre indicadores de segundo orden (contrastables empíricamente). El marco interpretativo MI1–MI3 opera sobre constructos sintéticos de tercer orden (no contrastable directo).

Los eventos observables (primer orden) son registros directos de acciones realizadas por el estudiante: clics, tipeos, prompts enviados, respuestas recibidas, tests ejecutados. Tienen marca temporal y contexto pero no constituyen aún evidencia evaluativa sin interpretación. Los indicadores derivados (segundo orden) son construcciones que sintetizan secuencias de eventos aplicando reglas de codificación explícitas: proporción de prompts reformulados, proporción de respuestas

verificadas ejecutivamente, tiempo promedio entre recepción de respuesta y siguiente acción. Son cuantitativos y objetivos pero ya incorporan decisiones interpretativas. Los constructos sintéticos (tercer orden) son abstracciones teóricas que no se definen mediante una fórmula sino mediante articulación conceptual: calidad epistémica, apropiación reflexiva en sentido fuerte, coherencia estructural multidimensional. Operan como horizontes interpretativos y su validación es indirecta, mediante triangulación con juicios expertos y con indicadores de segundo orden.

Tres marcos interpretativos de tercer orden articulan la lectura conceptual de los resultados sin pretender contrastación cuantitativa directa. El primero, MI1 (calidad epistémica de la trayectoria), formula que los perfiles tipológicos de apropiación capturados por el clasificador no son meramente conductuales sino epistémicamente diferenciados: el perfil reflexivo se sostiene sobre una relación con la IA en la que el estudiante interroga las razones, contrasta alternativas y verifica críticamente las propuestas, mientras que el perfil delegativo se sostiene sobre una relación en la que el estudiante recibe propuestas sin interrogarlas. La calidad epistémica no es propiedad observable directamente; es horizonte interpretativo de los indicadores de segundo orden. Su validación es indirecta y procede por triangulación con el juicio docente experto sobre las trayectorias y con la auto-reconstrucción del estudiante en entrevista.

El segundo, MI2 (apropiación reflexiva en sentido fuerte), formula que los perfiles clasificados como reflexivos por el sistema operacionalizan parcialmente — no agotan— el constructo filosófico-pedagógico de la apropiación en sentido fuerte. La apropiación en sentido fuerte implicaría que el estudiante puede explicar a posteriori el porqué de cada decisión interactuada con el asistente, integrar lo apropiado a su repertorio cognitivo activo y transferir lo aprendido a situaciones nuevas. El sistema instrumental captura proxies observacionales de este constructo (verificación crítica, reformulación productiva, integración con capacidad de explicación posterior) pero no el constructo entero. La distinción entre operacionalización empírica y constructo conceptual es deliberada y honra el principio de no-reducción del protocolo interpretativo (§7.4).

El tercero, MI3 (coherencia estructural multidimensional como horizonte evaluativo), formula que la coherencia estructural en sus tres dimensiones (CT, CCD, CII) opera como horizonte evaluativo del proceso cognitivo, distinto de las medidas individuales de cada dimensión. La coherencia estructural multidimensional no es la suma ni el promedio de las cinco métricas operacionalizadas en el clasificador; es la articulación interpretativa que el docente lee sobre el perfil conjunto. El rechazo explícito de la colapsación a un score único (§4.5)

honra este marco: la coherencia es horizonte de lectura, no escalar comparable. La validación de MI3 procede por triangulación con el juicio docente sobre los perfiles completos y con la inspección del lenguaje narrativo del clasificador (Sección 5.2) que el docente contrasta con su propio juicio profesional.

Estos tres marcos interpretativos no son hipótesis contrastables (las hipótesis contrastables son H1-H3 sobre indicadores de segundo orden, presentadas en la Sección 6.1) sino horizontes que orientan la lectura conceptual de los resultados empíricos. Confundir MI con H comprometería la integridad metodológica del trabajo. La validación indirecta de MI1-MI3 procede por consistencia entre los hallazgos cuantitativos de H1-H3 y los hallazgos cualitativos del piloto (Sección 8): si los perfiles diferenciados por H1 son reconocibles por los docentes y reconstruibles por los estudiantes con coherencia narrativa, MI1-MI3 reciben respaldo indirecto. Si la consistencia no se establece, la formalización conceptual debe revisarse antes que abandonar los indicadores empíricos.

4.4 Tres tipos de apropiación de la IA

Una contribución específica del modelo es la caracterización de tres perfiles tipológicos de apropiación de la IA observables al nivel N4: perfil de delegación pasiva, perfil de apropiación superficial y perfil de apropiación reflexiva. Estos perfiles tipológicos no son exhaustivos ni mutuamente excluyentes en sentido estricto (un mismo estudiante puede exhibir distintos perfiles en distintos momentos del curso) pero operan como categorías pedagógicamente productivas. La Tabla 2 sintetiza sus patrones observables característicos.

Tabla 2. Tres tipos de apropiación de la IA observables en el nivel N4 y patrones característicos.

Tipo	Patrones observables característicos
Delegación pasiva	Prompts genéricos (transcripción del enunciado), aceptación acrítica de la primera respuesta, ausencia de verificación ejecutiva, ausencia de reformulación, ausencia de preguntas sobre los fundamentos de la respuesta
Apropiación superficial	Prompts más elaborados que en delegación pero con intención de obtener soluciones directas, verificación ejecutiva básica (compila + tests parciales) sin verificación conceptual, reproducción de argumentos sin capacidad de explicarlos
Apropiación reflexiva	Prompts epistemológicamente productivos (preguntan por razones, comparan alternativas, solicitan verificación), verificación crítica con contraargumentación, reformulación productiva, integración con capacidad de

Tipo	Patrones observables característicos
	explicación posterior

La distinción entre los tres tipos es observacional, no moral: no se trata de juzgar al estudiante sino de caracterizar patrones de uso del asistente. Pedagógicamente, los tipos permiten orientar intervenciones específicas: un estudiante con perfil de delegación pasiva puede beneficiarse de indicaciones explícitas sobre formulación de prompts; uno con apropiación superficial, de discusiones sobre verificación conceptual; uno con apropiación reflexiva, de desafíos adicionales que profundicen su práctica.

4.5 Coherencia estructural como criterio evaluativo multidimensional

La evaluación del proceso mediante el modelo N4 procede no mediante agregación de puntajes por nivel sino mediante el análisis de coherencia estructural entre los niveles. Un proceso de alta calidad se caracteriza no por la sola presencia de actividad en todos los niveles sino por la articulación coherente entre ellos: la comprensión del problema (N1) se refleja en la estrategia (N2); las validaciones (N3) producen retroalimentación efectiva sobre los niveles anteriores; las interacciones con IA (N4) se integran a los otros niveles sin sustituirlos. La coherencia estructural se operacionaliza en tres dimensiones independientes (Tabla 3) que el modelo se rehúsa explícitamente a colapsar en un score único, por dos razones: las tres dimensiones capturan aspectos teóricamente distintos no reducibles a una dimensión común, y la colapsación facilitaría usos evaluativos reduccionistas de alto stake que el modelo explícitamente declara fuera de su alcance legítimo.

Tabla 3. Tres dimensiones de la coherencia estructural y sus indicadores derivados.

Dimensión	Indicadores de segundo orden y propósito analítico
Coherencia temporal (CT)	Densidad de eventos por minuto en ventanas de trabajo sostenido, proporción prompts/(prompts+ejecuciones), proporción de tiempo por nivel, estructura de transiciones entre niveles. Captura la articulación de los eventos en su evolución temporal.
Coherencia código-discurso (CCD)	Proximidad temporal entre prompts al tutor y ediciones de código, fracción de ediciones sin prompt cercano (ediciones huérfanas), alineamiento semántico entre verbalizaciones del chat y artefactos producidos. Captura el alineamiento entre lo que el estudiante hace y lo que

Dimensión	Indicadores de segundo orden y propósito analítico
	dice.
Coherencia inter-iteración (CII)	Estabilidad léxica intra-episodio (Jaccard de tokens entre prompts consecutivos), pendiente de complejidad de prompts, transferencia inter-episodio de criterios aprendidos. Captura la estabilidad de criterios al enfrentar problemas análogos.

Nota operativa sobre CT. El “rango saludable” del ratio prompt/(prompts+ejec) cercano a 1:1 que el sistema instrumental aplica como componente del cálculo de CT es decisión de diseño del implementador y no derivación de literatura cognitiva establecida; queda como operacionalización inicial sujeta a calibración empírica post-piloto-1 sobre las clasificaciones históricas.

Nota operativa sobre CCD. La operacionalización de CCD vigente en el piloto-1, denominada CCD-piloto-1, considera únicamente las anotaciones explícitas del estudiante como fuente de verbalización reflexiva, ya que la clasificación automática del tipo de prompt en categorías epistemológicas —diferida a Eje B post-defensa— no está implementada en el sistema instrumental actual y los prompts se emiten con etiqueta uniforme. La CCD conceptual completa, denominada CCD-conceptual, incluiría también prompts reflexivos y se materializará post-implementación del clasificador semántico; la validación intercoder $\kappa \geq 0,70$ del piloto-1 valida la operacionalización CCD-piloto-1, no la CCD-conceptual.

Estas tres dimensiones teóricas se operacionalizan en cinco métricas computables que el Clasificador N4 calcula sobre cada episodio cerrado, correspondencia que conviene explicitar para preservar la trazabilidad entre la formulación teórica y el registro persistido. La coherencia temporal (CT) mantiene su unidad porque la temporalidad intra-episodio no admite un desdoblamiento natural en sub-métricas. La coherencia código-discurso (CCD) se desdobra en CCD promedio, que captura la proximidad temporal entre prompts al tutor y ediciones de código, y CCD orphan ratio, que captura la fracción de ediciones sin prompt cercano; ambos sub-indicadores miden fenómenos cualitativamente distintos —densidad versus ausencia— que conviene observar por separado para no diluir la señal pedagógicamente relevante de las ediciones huérfanas en el promedio. La coherencia inter-iteración (CII) se desdobra en CII estabilidad, que captura la similitud léxica intra-episodio mediante Jaccard de tokens entre prompts consecutivos, y CII evolución intra-episodio, que captura la pendiente intra-episodio de complejidad de prompts dentro de una misma sesión de trabajo, complementada por CII evolución longitudinal, que captura la pendiente inter-

episodio de la categoría de apropiación a través de tareas análogas identificadas por una misma plantilla académica (Sección 5.2 sobre operacionalización); ambos sub-indicadores intra-episodio operan en la misma escala temporal pero responden a preguntas analíticas separables (similitud léxica versus elaboración creciente), y el indicador longitudinal opera en escala temporal distinta sobre la trayectoria del estudiante. La correspondencia 3 → 5 entre dimensiones teóricas y métricas operacionales refleja exactamente la estructura del registro JSONB persistido por el clasificador y se mantiene estable a través de las versiones del modelo.

Las tres dimensiones se calculan separadamente sobre cada episodio cerrado. La operacionalización de primera generación implementada en el sistema prototipo prioriza métricas computacionalmente livianas, deterministas y reproducibles bit-a-bit. La extensión hacia operacionalizaciones más sofisticadas —similitud semántica mediante embeddings para el override léxico de anotaciones, observación longitudinal multi-episodio para coherencia inter-iteración, postprocesamiento del contenido textual de las anotaciones— constituye agenda explícita de las líneas confirmatorias. Cabe señalar que la observación longitudinal multi-episodio para coherencia inter-iteración se ha materializado parcialmente en el sistema instrumental con la limitación de que las tareas prácticas huérfanas (sin identificador de plantilla) quedan excluidas del cálculo, condición consistente con la Sección 8 sobre estado del piloto.

4.6 Ejemplo canónico: trayectoria de alta coherencia sobre el problema del segundo mayor

Para ilustrar cómo el modelo opera sobre episodios concretos, se presenta un ejemplo canónico construido sobre patrones observados en el piloto, que no reproduce un episodio individual específico sino que sintetiza un caso prototípico de apropiación reflexiva. El problema enunciado es típico de CS1: encontrar el segundo mayor elemento de una lista de enteros, asumiendo que existe y que puede haber repetidos en el máximo. La trayectoria del estudiante recorre los cuatro niveles del modelo de manera articulada.

En el nivel N1 (Comprensión), el estudiante lee el enunciado y, ante la cláusula “puede haber repetidos en el máximo”, consulta al asistente con un prompt como: “¿El segundo mayor debe ser estrictamente menor que el máximo o puede ser igual?”. El asistente devuelve que depende de la definición y ofrece dos interpretaciones. El estudiante elige la interpretación estricta y anota en un comentario del código la decisión tomada. En el nivel N2 (Estrategia), escribe pseudocódigo en español: “recorrer la lista manteniendo dos variables: mayor y segundo_mayor”. Pregunta al asistente sobre la complejidad de alternativas como ordenar la lista, y recibe una comparación entre $O(n)$

y $O(n \log n)$. Adopta la alternativa $O(n)$. En el nivel N3 (Validación), escribe tests manuales: la lista [3, 1, 4, 1, 5, 9, 2, 6] debe dar 6; la lista [5, 5, 3] debe dar 3; la lista [5, 5] debe dar ¿qué? Reconsidera el problema y anota que debería levantar excepción o devolver un valor indicador. Consulta al asistente sobre convenciones del lenguaje, elige levantar ValueError y ejecuta los tests.

La interacción con IA al nivel N4 se manifiesta en los tres prompts formulados (sobre la interpretación del enunciado, sobre complejidad algorítmica comparativa, sobre convenciones del lenguaje), todos epistemológicamente productivos: no solicitan una solución directa sino razones y comparaciones. La verificación ejecutiva se realizó ante la sugerencia del asistente sobre ValueError. La apropiación es reflexiva: el estudiante puede explicar a posteriori por qué eligió cada alternativa. Este episodio exhibe alta coherencia estructural en sus tres dimensiones. La comprensión del problema se refleja en la estrategia adoptada (alta coherencia código-discurso). La estrategia produce artefactos validables y la validación retroalimenta la decisión sobre el caso límite (alta coherencia temporal). Las interacciones con IA orientan decisiones específicas del estudiante sin sustituirlas (perfil característico de apropiación reflexiva en N4). Un episodio contrafactual de delegación pasiva sobre el mismo enunciado exhibiría un único prompt genérico transcribiendo el enunciado, una sola edición de código pegado desde la respuesta del tutor, ninguna ejecución de tests previos al cierre y CCD orfanos alta por ediciones de código sin verbalización. La distinción observacional entre los dos perfiles es la base de la hipótesis H1.

5. Operacionalización: el Cognitive Trace Record y el Clasificador N4

5.1 El Cognitive Trace Record como artefacto evidencial

La operacionalización del Modelo N4 requiere un artefacto que persista los eventos observables del proceso cognitivo del estudiante con propiedades que sostengan la cadena inferencial de evidence-centered design. Ese artefacto es el Cognitive Trace Record (CTR), registro de eventos cognitivos del estudiante durante una sesión de trabajo sobre una tarea práctica. Cada acción del estudiante genera un evento que el sistema instrumental persiste en una cadena con dos propiedades estructurales relevantes: encadenamiento criptográfico inmutable mediante hash SHA-256 sobre serialización canónica, y vinculación de cada evento al estado del sistema (versión del prompt del tutor, configuración del clasificador) que lo produjo.

El diseño del CTR está inspirado en los estándares contemporáneos de trazabilidad de experiencias de

aprendizaje como Caliper Analytics 1.2 (1EdTech Consortium) y xAPI (Experience API, ADL Initiative), pero se distingue de ellos por dos extensiones epistemológicamente relevantes que esos estándares no contemplan en su forma canónica. El encadenamiento criptográfico inmutable sostiene que cualquier intento de tampering sobre un evento histórico produce automáticamente la invalidación de los hashes posteriores del mismo episodio, condición verificable algorítmicamente y que ningún estándar de learning analytics contemporáneo provee de forma nativa. El versionado vinculante de cada evento al estado del sistema (versión del prompt del tutor, configuración del clasificador, identificador del corpus de guardrails) sostiene la reproducibilidad inter-temporal del análisis, condición sin la cual cualquier reanálisis posterior podría operar sobre supuestos distintos a los que estaban activos cuando el estudiante trabajó. La compatibilidad técnica con un exporter conforme a Caliper Analytics o xAPI es agenda de extensión del sistema instrumental, no compromiso del presente paper.

La propiedad arquitectónica clave del CTR es el carácter append-only riguroso: los eventos nunca se modifican ni se eliminan. Esta inalterabilidad no es una promesa procedimental sino una propiedad criptográfica observable, funcionalmente análoga a las cadenas hash documentadas en aplicaciones a sectores con requerimientos de auditabilidad académica. Para la cátedra, la consecuencia práctica es que los registros producidos constituyen evidencia de calidad académica defendible: el docente puede afirmar, con respaldo criptográfico, que las trayectorias cognitivas sobre las cuales basa su retroalimentación son las trayectorias efectivamente producidas por sus estudiantes durante el período evaluado. La propiedad se verifica por suite de tests golden sobre el cómputo de hash de evento (`compute_self_hash`) y de hash de cadena (`compute_chain_hash`) sobre serialización canónica, con un genesis hash convencional como ancla del primer evento de cada episodio.

5.2 El Clasificador N4 sobre cinco coherencias agregadas

Sobre la base de los eventos persistidos en el Cognitive Trace Record y de los indicadores derivados de las tres dimensiones de coherencia, el Clasificador N4 asigna a cada episodio cerrado una de tres categorías de apropiación cognitiva: delegación pasiva, apropiación superficial o apropiación reflexiva. La decisión de implementar el clasificador como árbol de decisión explícito sobre coherencias calculables, en lugar de un clasificador supervisado opaco entrenado sobre un corpus etiquetado, es deliberada y vincula directamente con la utilidad pedagógica del instrumento. La transparencia del proceso

inferencial es condición de aceptabilidad académica de los sistemas que toman decisiones sobre estudiantes [11, 17], y la propiedad de reproducibilidad bit-exacta —dada la misma secuencia de eventos y el mismo reference profile, el clasificador produce siempre la misma clasificación— sostiene la auditabilidad del trabajo: dos docentes que ejecuten el clasificador sobre el mismo dataset obtienen los mismos resultados, condición de comparabilidad entre evaluaciones realizadas por distintos miembros del cuerpo docente. Esta propiedad se verifica por el test de reproducibilidad del pipeline mediante comparación contra hash golden.

El árbol de decisión calcula sobre cada episodio cinco coherencias agregadas que operan como las cinco claves planas del registro de coherencias persistido por episodio cerrado: coherencia temporal (CT) sobre densidad de eventos y prompt-exec ratio; coherencia código-discurso promedio (CCD prom) sobre proximidad temporal prompt-edición; coherencia código-discurso de huérfanas (CCD orfanos) sobre fracción de ediciones sin prompt cercano; coherencia inter-iteración estabilidad (CII estab) sobre similitud léxica intra-episodio; y coherencia inter-iteración evolución (CII evol) sobre tendencia de complejidad de prompts. Estas cinco coherencias materializan las tres dimensiones teóricas de la Tabla 3 mediante el desdoblamiento de CCD y CII en sus dos sub-métricas respectivas. La Fig. 3 representa el árbol de decisión que aplica reglas explícitas sobre las cinco coherencias para asignar categoría.




Figura 3. Árbol de decisión del Clasificador N4 sobre cinco coherencias agregadas. La categoría “apropiación superficial” opera como rama por defecto cuando no se cumplen las condiciones de las dos ramas distintivas. La salida incluye explicación textual con valores observados de coherencias.

Cada clasificación devuelve, junto con la categoría, una explicación textual que articula los valores observados de las coherencias y la rama del árbol que aplicó. Esta explicación es lo que el docente lee cuando revisa la trayectoria de un estudiante: no recibe una etiqueta opaca sino una narrativa razonada sobre por qué el sistema clasificó el episodio del modo que lo hizo, narrativa que el docente puede contrastar con su propio juicio profesional. La articulación entre clasificación automática y juicio docente es lo que hace al sistema usable en el aula universitaria, en lugar de un instrumento cerrado que dictamina sobre los estudiantes. La salida del clasificador incluye además el `classifier_config_hash`, identificador criptográfico de la versión del `reference profile` activo al momento de la clasificación, propiedad estructural que sostiene la reproducibilidad inter-temporal del análisis.

El sistema instrumental desplegado en el piloto contempla además una serie de capacidades de plataforma cuya formalización académica excede el alcance del presente paper pero que conviene mencionar para integridad de la descripción operacional: gestión de claves de proveedores LLM aportadas por los docentes con encriptación AES-256-GCM y resolución jerárquica por materia, facultad y tenant (ADR-038, ADR-039, ADR-040); attestations Ed25519 producidas como side-channel del cierre de cada episodio para evidencia criptográfica externa, independiente del propio encadenamiento SHA-256 del CTR (ADR-021); gate de k-anonimato sobre endpoints cohortales que degrada gracilmente a indicador de muestra insuficiente cuando hay menos de cinco estudiantes con suficiente data (ADR-022); multi-tenancy basada en Row-Level Security de Postgres con aislamiento a nivel de base de datos (ADR-001); plantillas de tareas prácticas con auto-instanciación por comisión y control de drift independiente (ADR-016); generación asistida por IA de tareas prácticas con prompt versionado (ADR-036); reflexión metacognitiva post-cierre persistida como evento del CTR pero explícitamente excluido del feature extraction del clasificador para preservar la reproducibilidad bit-a-bit de las clasificaciones históricas (ADR-035); y sandbox client-side de ejecución de código con Pyodide, diferido al piloto-2 por consideraciones de validación de seguridad (ADR-033, ADR-034). Cada una de estas capacidades responde a requerimientos de despliegue institucional —privacidad, auditabilidad, federación de identidad, escalabilidad— sin alterar las propiedades estructurales del Modelo N4 ni del CTR, y queda documentada de manera canónica en su Architectural Decision Record correspondiente.

6. Diseño cuasi-experimental para la validación

La validación empírica del Modelo N4 se conduce mediante un diseño cuasi-experimental específico, dentro de un marco metodológico general de Design-Based Research. La adopción del diseño cuasi-experimental, y no experimental puro, responde a las restricciones inherentes al contexto educativo real donde la asignación aleatoria de estudiantes a condiciones está limitada por consideraciones pedagógicas y éticas, y donde la existencia de cohortes naturales preexistentes (comisiones, grupos de clase) hace pragmáticamente inviable la randomización al nivel individual. Shadish, Cook y Campbell [22] proporcionan el marco conceptual adoptado: los diseños cuasi-experimentales preservan el requisito de manipulación sistemática de la condición independiente pero renuncian al requisito de asignación aleatoria, a cambio de cuidado específico en el control de amenazas a la validez.

6.1 Hipótesis contrastables

Tres hipótesis operativas estructuran la validación, distinguidas explícitamente del marco interpretativo de orden superior que opera como horizonte de lectura de los resultados.

H1 (Diferenciabilidad observacional). Los perfiles estructurales de trayectoria cognitiva, reconstruidos a partir del Cognitive Trace Record y clasificados mediante el Modelo N4, permiten distinguir observacionalmente entre episodios correspondientes a distintos tipos de apropiación de la IA (delegación pasiva, apropiación superficial, apropiación reflexiva).

H2 (Asociación con desempeño). La coherencia estructural multidimensional del proceso, medida en sus tres dimensiones, se asocia con indicadores de desempeño independientes en tareas de transferencia, controlando por nivel inicial de competencia.

H3 (Validez del clasificador). El Clasificador N4 alcanza fiabilidad intercodificador sustancial ($\kappa \geq 0,70$ conforme a Landis y Koch 1977) ante anotadores humanos capacitados, en una muestra estratificada conforme al protocolo dual descrito en la Sección 7: Protocolo A con 200 eventos estratificados (50 por nivel cognitivo N1-N4) para validar el etiquetador, y Protocolo B con 50 episodios cerrados distribuidos entre las tres categorías de apropiación para validar el árbol de decisión, totalizando 250 unidades anotadas que cubren los cuatro niveles cognitivos y las tres categorías de clasificación.

6.2 Condiciones, variables e instrumentos

El estudio compara dos condiciones en cohortes paralelas de un mismo curso. La condición experimental utiliza la instrumentación del Modelo N4 en el desarrollo de las actividades, con sus interacciones registradas en el

CTR y clasificadas mediante el Clasificador N4. La condición de comparación realiza las actividades del curso con metodología tradicional, sin interactuar con el sistema instrumentado, y tiene acceso a los recursos habituales del curso. Ambas condiciones son expuestas a las mismas tareas de transferencia y evaluaciones convencionales, que constituyen las medidas de desempeño utilizadas para la comparación en H2. La Tabla 4 sintetiza variables e instrumentos del diseño.

Tabla 4. Variables e instrumentos del diseño cuasi-experimental.

Tipo	Variable	Instrumento
Independiente	Condición de uso	Asignación experimental vs. comparación
Dependientes principales	Coherencia estructural (3 dim), tipo de apropiación, desempeño en transferencia	Indicadores derivados del CTR, Clasificador N4, pruebas comunes a ambos grupos
De control	Nivel inicial de competencia, experiencia previa con IA	Pretest estandarizado, cuestionario inicial
Cualitativas	Reconstrucción del proceso por el estudiante, juicio docente sobre trayectoria	Entrevistas semi-estructuradas con submuestra estratificada, análisis temático

La población es estudiantes de primer y segundo año de carreras de informática y sistemas. El análisis de potencia estadística a priori, conforme a Cohen [6], establece para detectar efectos de tamaño $d \geq 0,5$ con potencia del 80 % y $\alpha = 0,05$ un n mínimo por grupo de 64 estudiantes. La muestra del piloto se constituye con voluntarios que aceptan participar mediante consentimiento informado. La Tabla 5 sintetiza la articulación entre las hipótesis y las métricas que las validan.

Tabla 5. Hipótesis contrastables, indicadores principales y criterios de validación.

Hip.	Indicador principal	Criterio de validación
H1	Distancia entre perfiles vectoriales de coherencia entre las tres categorías	ANOVA / Kruskal-Wallis sobre cada dimensión, Manova multivariada, efecto observacional con $\eta^2 \geq 0,06$
H2	Correlación entre coherencia	Spearman ρ con corrección por nivel pretest, regresión

Hip.	Indicador principal	Criterio de validación
	estructural y desempeño en tareas de transferencia	múltiple, IC95% que excluya 0
H3	Acuerdo intercodificador entre Clasificador y dos anotadores humanos	$\kappa \geq 0,70$ (acuerdo sustancial, Landis y Koch 1977) en al menos dos de los tres pares evaluados (Clasificador vs Anotador 1, Clasificador vs Anotador 2, Anotador 1 vs Anotador 2), reportado por separado para el Protocolo A (etiquetado N1-N4 sobre 200 eventos estratificados) y para el Protocolo B (clasificación de apropiación sobre 50 episodios cerrados)

6.3 El confound intervención-medición

La presente sección discute explícitamente una limitación metodológica central del diseño que no puede ser resuelta en el marco del estudio piloto y cuya explicitación es requisito de integridad científica. La instrumentación del Modelo N4 desempeña dos funciones simultáneas que en un diseño experimental idealmente estarían separadas: opera como intervención pedagógica (la condición experimental que se manipula) y como instrumento de medición (el mecanismo que produce los datos sobre los que se realizan las inferencias). Esta dualidad funcional produce un confound estructural: las diferencias observadas entre condiciones podrían deberse tanto a efectos de la intervención pedagógica como a diferencias en la observabilidad del proceso. Concretamente, los estudiantes del grupo experimental tienen sus procesos registrados en granularidad fina por el CTR; los del grupo de comparación no. La comparación entre grupos en términos de desempeño en tareas de transferencia es metodológicamente sólida, pero la atribución causal de las diferencias a la intervención pedagógica específica (separadamente del efecto de la observación) excede las posibilidades del presente diseño.

Esta limitación no es un defecto local sino una propiedad estructural del problema: cualquier sistema de medición fina del proceso es, simultáneamente, una intervención. McCambridge, Witton y Elbourne [14], en su revisión sobre efectos de participación en estudios, documentan la ubicuidad de los efectos de medición y sugieren que su tratamiento debe ser explícito, no negado. Las estrategias de mitigación adoptadas son tres: análisis intra-grupo del grupo experimental (las asociaciones entre coherencia estructural y desempeño, reportadas como parte de H2, son internas al grupo y no dependen de la

comparación entre grupos); triangulación con fuentes independientes (entrevistas que permiten contrastar la reconstrucción basada en el CTR con la auto-reconstrucción del estudiante); y formulación de una agenda confirmatoria explícita (sección 8) que descomponga factorialmente el confound mediante diseños posteriores con grupos adicionales que reciban la intervención sin la medición fina.

7. Protocolo de validación intercodificador y reproducibilidad del estado del sistema

7.1 Protocolo dual con kappa de Cohen


La validación específica de la hipótesis H3 procede mediante el procedimiento estándar de fiabilidad intercodificador con kappa de Cohen [5, 6]. El coeficiente kappa, definido como el acuerdo observado corregido por el acuerdo esperado por azar, descuenta el acuerdo atribuible a la distribución marginal de las categorías y proporciona una medida más conservadora y comparable que el mero porcentaje de acuerdo. La interpretación adopta la convención de Landis y Koch [12]: valores entre 0,00 y 0,20 representan acuerdo leve; 0,21–0,40 justo; 0,41–0,60 moderado; 0,61–0,80 sustancial; 0,81–1,00 casi perfecto. El umbral de aceptación adoptado para H3 es $\kappa \geq 0,70$, cómodamente en la franja sustancial, valor que aplica

tanto al Protocolo A (etiquetado de eventos contra los cuatro niveles N1–N4) como al Protocolo B (clasificación de episodios cerrados en las tres categorías de apropiación) descritos abajo. La elección de 0,70 en lugar del límite inferior 0,61 del rango sustancial responde a dos consideraciones: por un lado deja margen para varianza muestral del estimador kappa con N moderado ($\approx \pm 0,06$ con $N = 50\text{--}200$), y por otro alinea el umbral con la convención del campo de evidence-centered design [15]. Este umbral es exigente sin ser irrazonable para el tipo de clasificación en cuestión, donde las categorías tienen fronteras con cierto grado de borrosidad inherente.

La Fig. 4 representa el flujo del protocolo en sus seis pasos articulados, con dos puntos de decisión que regulan la continuidad o el refinamiento iterativo del procedimiento.

Figura 4. Protocolo de validación intercodificador del Clasificador N4. Dos puntos de decisión regulan la continuidad: el primero tras la prueba piloto (calibración si κ por debajo del umbral aceptado), el segundo tras la codificación principal (refinamiento del clasificador si persiste por debajo del umbral).

El protocolo de validación intercodificador adoptado es dual y comprende dos componentes paralelos sobre dos



objetos de fiabilidad teóricamente distintos. El Protocolo A valida el etiquetador del sistema, sometiendo 200 eventos estratificados —50 por nivel cognitivo N1-N4— a anotación independiente por dos docentes que asignan a cada evento una de las cuatro etiquetas del modelo; el kappa de Cohen se reporta por par de anotadores y entre Clasificador y cada anotador, con el criterio de aceptación $\kappa \geq 0,70$ sustancial. El Protocolo B valida el árbol de decisión que produce la categoría de apropiación, sometiendo 50 episodios cerrados distribuidos aproximadamente equilibradamente entre las tres categorías esperadas (delegación pasiva, apropiación superficial, apropiación reflexiva) a clasificación independiente por los mismos dos docentes; el kappa se reporta del mismo modo y con el mismo criterio de aceptación. La separación es metodológicamente exigida porque un evento individual se etiqueta como N1, N2, N3 o N4 mientras que un episodio cerrado se clasifica en una de las tres categorías de apropiación: son dos cadenas inferenciales distintas y la fiabilidad de cada una debe reportarse de manera independiente. El costo operacional total es de 250 unidades por anotador (200 eventos + 50 episodios), más una sesión preparatoria de calibración conjunta sobre 20 episodios distintos del corpus de validación.

La muestra de validación contempla la cobertura estratificada de los cuatro niveles del modelo, con tamaño definido conforme a la Decisión Pendiente sobre el tamaño de muestra (ver H3, Sección 6.1). La distribución estratificada es importante para evitar que categorías menos frecuentes (típicamente N1 si los estudiantes tienden a saltarla) queden subrepresentadas en la evaluación de fiabilidad. Dos anotadores humanos independientes —docentes auxiliares del curso con formación específica sobre el Modelo N4— reciben capacitación mediante un documento de referencia que define operacionalmente cada categoría con ejemplos prototípicos y casos límite, y mediante una sesión de codificación conjunta sobre 20 episodios de calibración. Las anotaciones del Clasificador N4 se mantienen ocultas durante el proceso de codificación humana para garantizar independencia.

Tras la codificación independiente sobre la muestra completa, se calculan tres pares de kappa: Clasificador vs. Anotador 1, Clasificador vs. Anotador 2, y Anotador 1 vs. Anotador 2. El reporte incluye el valor de κ con su intervalo de confianza al 95 %, la matriz de confusión entre categorías, el número de episodios procesados, y la categorización del nivel de acuerdo. Si el kappa observado cae en el tramo entre 0,40 y el umbral mínimo aceptado, el protocolo prescribe una sesión de calibración entre los anotadores para revisar los desacuerdos episodio por episodio, refinar los criterios escritos de las tres categorías, y muestrear 50 episodios distintos sin reusar la muestra

previa para evitar sesgo de ajuste. Si el kappa permanece bajo 0,40 tras dos rondas, se reformulan los criterios operativos del clasificador y se reinicia la validación. El análisis de discrepancias incluye exploración cualitativa de patrones sistemáticos: si dos categorías específicas se confunden con frecuencia, esto sugiere refinamiento de la frontera operativa entre ellas o reconsideración de la rama del árbol de decisión correspondiente.

7.2 Reproducibilidad como propiedad del estado del sistema

La garantía de reproducibilidad del análisis, que el paper afirma para el Clasificador N4, conviene reformularse de manera más rigurosa como una propiedad del estado completo del sistema en un tiempo determinado y no como una propiedad invariante del clasificador aislado. Esta reformulación es necesaria porque la inferencia evidencial sobre el proceso cognitivo del estudiante involucra a más componentes versionados que el solo árbol de decisión, y la auditoría retrospectiva del análisis exige reconstruir el estado conjunto de todos ellos en el momento en que cada evento se persistió.

El sistema instrumental incorpora un conjunto coherente de constantes versionadas con fórmulas canónicas idénticas que extienden la garantía de reproducibilidad a múltiples componentes. El `classifier_config_hash` versiona el reference profile del clasificador. El `guardrails_corpus_hash`, computado mediante `sha256(json.dumps(corpus_dict, sort_keys=True, ensure_ascii=False, separators=(",", ":")))`, versiona el corpus completo de patrones regex y umbrales de detección de comportamiento adverso; sus bумpeos —documentados como `GUARDRAILS_CORPUS_VERSION` evolutivo— quedan reflejados en cada evento `intento_adverso_detectado`. El `chunks_used_hash`, computado mediante `sha256(''.join(sorted(str(id) for id in chunk_ids)).encode('utf-8'))`, y formalizado en RN-026, versiona el conjunto de chunks RAG recuperados por turno y viaja desde el evento `prompt_enviado` hasta el `tutor_respondio` del mismo turno, permitiendo auditoría retrospectiva de qué material conocía el tutor cuando produjo cada respuesta específica. La versión del etiquetador de niveles (`LABELER_VERSION`) viaja en cada evento del CTR y evoluciona en bумpeos minor que extienden las reglas de mapeo de eventos a niveles cognitivos.

La historia evolutiva del `LABELER_VERSION` ilustra concretamente cómo opera la reproducibilidad del estado del sistema. La versión v1.0.0 definió el mapeo base donde `anotacion_creada` se etiquetaba como N2 fijo. La versión v1.1.0, formalizada en el ADR-023, introdujo el override temporal posicional (anotaciones tempranas como N1, anotaciones post-respuesta como N4). La versión vigente

v1.2.0, formalizada en el ADR-034, agrega la regla N3/N4 para tests_ejecutados: tests pasados con ventana mayor a sesenta segundos desde el último tutor_respondido se etiquetan como N4 reflexivo; con fallos o ventana insuficiente se etiquetan como N3. Cada bumpeo de versión re-etiqueta históricos sin tocar el CTR pero requiere actualización explícita de la documentación de la tesis sobre el sesgo que cierra cada versión.

La reproducibilidad, en sentido estricto, opera entonces sobre el estado completo del sistema en un tiempo determinado: cualquier reanálisis posterior puede reconstruir qué versión de cada componente estaba activa cuando cada evento se persistió, y aplicar el análisis con ese estado para obtener resultados bit-a-bit idénticos a los originales. Conviene declarar transparentemente, sobre esta base, una deuda operacional del piloto-1: el sistema acumuló un conjunto de 106 clasificaciones cuyo hash fue computado con una versión anterior del etiquetador (previa al bumpeo a LABELER_VERSION = "1.2.0"). Estas clasificaciones siguen siendo reproducibles bit-a-bit contra su propio hash original —cualquier auditor que recompute con la versión que las generó obtiene el mismo resultado— pero recomputarlas con la versión vigente del etiquetador produciría hashes nuevos. El plan de re-clasificación masiva está formalizado como acción A1 del plan operativo del proyecto y requiere acceso a la base de datos real del piloto. Hasta que se ejecute, la garantía de reproducibilidad del análisis aplica plenamente a las clasificaciones posteriores al bumpeo y se relativiza para las 106 previas en términos de qué versión específica fue usada para generarlas, condición que el comité doctoral puede verificar accediendo al hash registrado en cada clasificación.

7.3 Consideraciones de equidad y sesgo del criterio de coherencia

El criterio de coherencia estructural, aunque epistemológicamente fundado, no es un criterio neutral respecto de estilos de aprendizaje y de configuraciones culturales del estudiante. Una discusión honesta de sus limitaciones exige reconocer cuatro modos en que podría desfavorecer sistemáticamente a ciertos perfiles. Primero, los estilos de aprendizaje no lineales, documentados en la literatura sobre creatividad y aprendizaje, exhiben múltiples saltos entre niveles, experimentación lateral y exploración de alternativas no directamente vinculadas a la solución final. Estos estilos pueden ser clasificados erróneamente como baja coherencia temporal cuando en realidad constituyen un patrón productivo distinto. La mitigación se realiza mediante la conservación del perfil multidimensional (no colapsado a un score único) y el contraste con triangulación cualitativa.

Segundo, los patrones culturales diversos presuponen que el estudiante verbaliza sus decisiones en el chat con el

tutor. Estudiantes de culturas o contextos donde la verbalización del proceso no es parte del repertorio habitual pueden exhibir baja coherencia código-discurso sin que esto refleje deficiencia en su proceso cognitivo. La mitigación incluye la posibilidad de modalidades alternativas de registro de discurso (comentarios estructurados en el código, notas personales en el sistema). Tercero, los estudiantes con discapacidades o necesidades específicas pueden encontrar barreras de accesibilidad que afecten diferencialmente el registro observable; el monitoreo de estos efectos es parte de la agenda de investigación responsable. Cuarto, la brecha digital previa puede manifestarse en los primeros episodios como patrones que se asemejan a delegación pasiva pero que reflejan exploración inicial más que patrón estable. La observación longitudinal es esencial para no hacer diagnósticos prematuros.

Estas consideraciones de equidad no invalidan el criterio pero exigen uso cauteloso. Por esta razón, el modelo se propone explícitamente como instrumento diagnóstico para la orientación pedagógica, no como instrumento de selección o acreditación de alto stake. El protocolo interpretativo de los resultados incorpora siete principios rectores: contextualidad (toda lectura considera el contexto institucional), no-reducción (los constructos sintéticos no se reducen a indicadores), triangulación obligatoria (toda inferencia involucra al menos dos fuentes independientes), no-etiquetado individual (las categorías describen episodios, no estudiantes), no-uso para alto stake sin triangulación, explicitación de versión (todo reporte incluye classifier_config_hash) y apertura a la crítica (los datos están disponibles para reanálisis externo). La operacionalización de estos principios en el sistema instrumental incorpora un gate de k-anonimato que filtra cualquier endpoint de analítica cohortal que opere sobre menos de cinco estudiantes, devolviendo una marca de datos insuficientes antes de exponer cuartiles que podrían reconstruir trayectorias individuales en cohortes pequeñas.

8. Hallazgos preliminares del piloto, estado del sistema instrumental y agenda confirmatoria

El sistema instrumental que materializa el Modelo N4 fue desplegado durante el ciclo lectivo 2026 en un piloto universitario que registra al cierre de este reporte 106 clasificaciones persistidas sobre el orden de cien episodios cerrados. Cabe declarar como deuda explícita del piloto que las 106 clasificaciones históricas fueron selladas con una versión del etiquetador anterior al bump más reciente de la constante de versión del etiquetador (LABELER_VERSION 1.2.0); la re-clasificación de ese histórico bajo la versión vigente del etiquetador es una

tarea pendiente del plan operativo que requiere acceso a la base de datos real del piloto, y constituye uno de los pasos necesarios para el cierre cuantitativo de las hipótesis H1 y H2. La distancia entre el n del piloto actual y el n mínimo de 64 estudiantes por grupo derivado del análisis de potencia estadística de la Sección 6.2 explicita que la contrastación cuantitativa sigue dependiendo del cierre del reclutamiento del grupo de comparación.

Los hallazgos cualitativos del pilotaje, que pueden reportarse con el carácter provisorio propio del análisis en curso, sugieren patrones consistentes con las hipótesis operativas. Los estudiantes del grupo experimental exhibieron diferenciación observacional entre los tres tipos de apropiación; el Clasificador N4 produjo perfiles que fueron reconocibles por los docentes cuando se les presentaron anonimizados; las discusiones con los estudiantes en las entrevistas mostraron que el modelo capturaba diferencias fenomenológicamente reconocibles para ellos. Tres patrones específicos merecen mención. Primero, los estudiantes con perfil inicial de delegación pasiva que recibieron retroalimentación específica del sistema mostraron, en los episodios subsiguientes, mayor frecuencia de prompts reformulados y mayor presencia de eventos N1 (comprensión). Segundo, los estudiantes con perfil inicial de apropiación reflexiva mantuvieron sus patrones con cierta variabilidad pero sin regresión sistemática a modos más superficiales. Tercero, los estudiantes con perfil intermedio (apropiación superficial) mostraron mayor heterogeneidad en sus trayectorias, con algunos avanzando hacia apropiación reflexiva y otros oscilando.

Estos patrones son consistentes con el marco interpretativo MI1–MI3 pero no deben confundirse con contrastación cuantitativa de las hipótesis. La contrastación cuantitativa de H1, H2 y H3 requiere el cierre del estudio empírico principal, en curso al momento de la submisión. La Tabla 6 sintetiza el estado de cada componente del reporte empírico al momento de cierre.

Tabla 6. Estado del reporte empírico al momento de cierre.

Componente	Estado	Próximo hito
Modelo N4: formalización conceptual	Cerrado	—
Sistema instrumental v1.2.0	Desplegado	11 servicios HTTP operativos, 23 de 26 acciones del plan ejecutadas, 11 de 20 capabilities funcionales al 100 % bajo cuatro criterios estrictos (código + tests + docs sin DEFERRED activo; invariantes técnicas verificadas; en producción en

Componente	Estado	Próximo hito
		piloto con números verificables; aprobada académicamente). Detalle en documento operacional auxiliar de auditoría del repositorio.
Hallazgos cualitativos del piloto	Provisorios	Análisis temático completo de entrevistas
Validación intercoder (H3)	En ejecución	Cierre del protocolo dual y reporte de $\kappa \geq 0,70$ para Protocolo A (etiquetado N1-N4 sobre 200 eventos) y Protocolo B (categorías de apropiación sobre 50 episodios), por separado
Análisis cuantitativo H1, H2	Pendiente	Cierre del reclutamiento del grupo de comparación y re-clasificación de las 106 clasificaciones históricas con LABELER_VERSION vigente
Análisis factorial exploratorio	Pendiente	EFA con KMO, Bartlett y análisis paralelo

Cinco riesgos específicos del estudio se declaran a priori, con sus estrategias de mitigación respectivas: efecto Hawthorne (mitigación por extensión temporal del piloto), performatividad cognitiva (mitigación por análisis intra-grupo), deriva comportamental del LLM subyacente (mitigación por versionado del prompt), brecha digital previa (mitigación por observación longitudinal antes que diagnóstico prematuro) y sobrecarga cognitiva (mitigación por diseño de la interfaz con feedback continuo). La agenda confirmatoria explícita comprende siete líneas: descomposición factorial del confound intervención-medición, replicación multisite, análisis factorial confirmatorio sobre muestra independiente, extensión a otros dominios cognitivos, estudios longitudinales, integración institucional a gran escala, e investigación metacognitiva sobre los efectos del propio uso del modelo en la auto-percepción del estudiante.

9. Discusión: posicionamiento del Modelo N4 frente a la literatura reciente

El Modelo N4 dialoga con tres cuerpos de literatura reciente que conviene posicionar explícitamente. El primero es el cuerpo de revisiones sistemáticas sobre IA generativa en educación de programación. Las cinco revisiones identificadas en la sección 2 cubren parcialmente el campo pero ninguna articula

simultáneamente las dimensiones que el presente modelo aborda. La revisión amplia de Elnaffar et al. opera sobre toda la educación universitaria sin foco disciplinar; la de Reihanian et al. enfoca personalización con énfasis en métricas de desempeño sin tomar posición sobre el régimen de uso del asistente; la de Bernstein et al. documenta empíricamente daños cognitivos pero sin ofrecer aparato analítico para distinguir tipos de apropiación; la de Prather et al. problematiza la dimensión cualitativa sin instrumento evaluativo replicable; la revisión bibliométrica sobre metacognición en STEM identifica el cognitive offloading como constructo emergente sin instrumento estandarizado de medición. El Modelo N4 no es alternativo a estas revisiones sino complementario: ofrece un aparato conceptual operacionalizable que podría servir como instrumento común para que estudios futuros cuantifiquen rigurosamente la incidencia de los tres tipos de apropiación en distintos contextos.

El segundo cuerpo de literatura es el de tutores inteligentes basados en LLM con configuración pedagógica explícita. Trabajos como AutoTutor con guardarraíles [3] y SocraticAI [18] han consolidado la observación de que la mera disponibilidad de un asistente generativo en el contexto educativo no produce automáticamente beneficio pedagógico, y que la productividad efectiva del asistente depende de su configuración pedagógica explícita. El presente modelo extiende este hallazgo en una dirección específica: la configuración pedagógica del tutor es condición necesaria pero no suficiente. La condición complementaria es la instrumentación del proceso cognitivo del estudiante en interacción con el tutor configurado, lo cual permite distinguir si el estudiante aprovecha efectivamente el régimen socrático del asistente o desarrolla estrategias de elusión que conducen a apropiación superficial pese a la configuración del tutor. La articulación entre tutor configurado y CTR instrumentado es lo que sostiene la diferencia.

El tercer cuerpo de literatura es el de evaluación basada en procesos y learning analytics. La tradición de evidence-centered design [14] aporta el aparato conceptual general pero su aplicación al dominio específico de programación con IA generativa exige extensiones. Las revisiones recientes sobre métodos de inteligencia artificial explicable en educación [11, 17] consolidan que la transparencia del proceso inferencial es condición de aceptabilidad académica de los sistemas que toman decisiones sobre estudiantes. El Modelo N4 se inscribe en esta tradición mediante tres decisiones específicas: implementación del clasificador como árbol explícito (no modelo supervisado opaco), reproducibilidad bit-exacta de las clasificaciones, y narrativa textual de explicación que el docente puede contrastar con su propio juicio profesional. La articulación entre transparencia técnica y juicio profesional docente es

lo que diferencia al modelo de propuestas que pretenden reemplazar la evaluación docente por automatización opaca.

Un segundo posicionamiento epistemológico merece tematizarse antes del cierre. El presente trabajo presenta un sistema de medición del proceso cognitivo del estudiante en interacción con un asistente de IA, no un sistema de medición del aprendizaje en sentido cognitivo estricto. La distinción es fundacional en el campo de la medición educativa contemporánea: Pellegrino, Chudowsky y Glaser [18], en su síntesis fundamental sobre evaluación basada en evidencia, distinguen entre process assessment (medición de patrones del proceso cognitivo) y learning assessment (medición del cambio cognitivo entre estados, típicamente pre y post intervención). El sistema instrumental que materializa el Modelo N4 opera explícitamente sobre el primer registro: las cinco coherencias agregadas, los indicadores derivados y los perfiles tipológicos de apropiación capturan patrones observables del uso del asistente, no el aprendizaje individual generalizable. La hipótesis H1 se formula con precisión sobre esta operacionalización: postula diferenciabilidad observacional entre tipos de apropiación, no entre niveles de aprendizaje. La hipótesis H2 articula la asociación con desempeño en tareas de transferencia como articulación necesaria entre process assessment y learning assessment, articulación que el piloto actual no resuelve completamente porque el instrumento de transfer está operacionalizado pero el reclutamiento del grupo de comparación sigue en curso.

La consecuencia metodológica honesta es que las afirmaciones del paper sobre apropiación deben leerse como afirmaciones sobre proceso observable, no como afirmaciones sobre aprendizaje individual generalizable. Un estudiante clasificado con perfil reflexivo durante un episodio puede o no estar aprendiendo en sentido cognitivo estricto; el clasificador no responde esa pregunta. Lo que responde es: el perfil de uso del asistente que el estudiante exhibió en este episodio es distinguible observacionalmente de los perfiles delegativo o superficial. La validación de la asociación entre perfil de uso y aprendizaje generalizable es objeto del análisis cuantitativo de H2, pendiente al cierre de esta versión del reporte, y constituye uno de los hitos del estudio empírico completo. La distinción entre process assessment y learning assessment no es debilidad sino integridad metodológica: el modelo afirma exactamente lo que opera para verificar, y declara explícitamente lo que sus instrumentos no permiten todavía concluir.

Una limitación del presente posicionamiento merece explicitarse. El Modelo N4 fue formulado en el contexto institucional argentino, sobre cohortes de carreras de informática y sistemas en una universidad nacional argentina, con estudiantes que cursan en español y con

materiales de cátedra producidos en español. La generalización a otros contextos institucionales, otros idiomas de cursada (particularmente al portugués brasileño y al inglés de carreras internacionales), otros sistemas educativos y otras culturas pedagógicas requiere replicación específica. La línea de replicación multisite, declarada como Línea 2 de la agenda confirmatoria, articula los criterios para esta extensión: invariantes de diseño que deben preservarse (los cuatro niveles del modelo, los tres tipos de apropiación, las tres dimensiones de coherencia, el target kappa adoptado) y dimensiones variables que pueden adaptarse al contexto local (ventanas temporales del etiquetador, criterios específicos de calibración del prompt del tutor, granularidad de los eventos del CTR). El presente paper formula el modelo y propone su validación inicial; la consolidación cross-cultural es objeto explícito de trabajo futuro.

10. Conclusiones

El presente trabajo formalizó el Modelo N4 de Trazabilidad Cognitiva como respuesta articulada a la crisis evaluativa contemporánea de la formación universitaria de programación con asistentes de IA generativa. La contribución se sitúa en cuatro niveles. En el nivel conceptual, la formalización del modelo con la interacción con IA como nivel analítico autónomo, los tres tipos de apropiación observacionalmente distinguibles, y la coherencia estructural multidimensional como criterio evaluativo. En el nivel evaluativo, el desplazamiento del foco desde el producto (código entregado, opaco bajo mediación de IA) hacia el proceso (trayectoria registrada, observable bajo instrumentación). En el nivel metodológico, la propuesta de validación con tres hipótesis contrastables, un diseño cuasi-experimental con declaración explícita del confound intervención-medición, y un protocolo de fiabilidad intercodificador alineado con la convención de Landis y Koch. En el nivel epistemológico, la distinción entre tres órdenes de constructos —observables, indicadores derivados, sintéticos— que evita confusiones entre niveles de análisis y sitúa adecuadamente las afirmaciones de validez del trabajo.

La integridad epistemológica del trabajo se sostiene en lo que el modelo es y, en igual medida, en lo que el modelo declara explícitamente no ser. El Modelo N4 es un marco analítico para observar el proceso de resolución, una propuesta operacionalizable mediante instrumentación auditable, un aparato conceptual para evaluación basada en coherencia estructural, y una contribución abierta a contrastación empírica y refinamiento. El Modelo N4 no es una taxonomía pedagógica universal de tipo Bloom, no es un sistema de acreditación de alto stake, no asigna etiquetas

globales a estudiantes, no es una caja negra algorítmica, y no es una respuesta definitiva al problema de la evaluación en la era de los asistentes de IA generativa: es una contribución, no un cierre. La agenda confirmatoria explícita formulada en la sección 8 articula las extensiones necesarias para consolidar las afirmaciones del modelo más allá del piloto inicial.

Apéndice A — Notas operativas del sistema instrumental

El presente apéndice documenta las propiedades arquitectónicas críticas del sistema instrumental que materializa el Modelo N4. Su función es la de “implementation notes” complementarias al cuerpo argumentativo del paper: el lector interesado en la auditoría académica del piloto encuentra acá los detalles operacionales que sostienen las afirmaciones de reproducibilidad, escalabilidad y gobernanza realizadas en el cuerpo del trabajo. Las cuatro sub-secciones que siguen son verificables directamente contra el repositorio del proyecto.

A.1 Sharding del CTR a nivel del bus

El Cognitive Trace Record opera con sharding de 8 particiones a nivel del bus Redis Streams. El sistema instrumental define la constante `NUM_PARTITIONS = 8` y deriva el shard de cada episodio mediante un hash determinista del identificador del episodio: `shard = int.from_bytes(sha256(episode_id).digest()[:4], "big") % 8`. Esta función de hash garantiza distribución uniforme y, más importante, estabilidad: el mismo episodio cae siempre en la misma partición a lo largo de toda su vida útil. La propiedad de single-writer por partición se preserva al asignar exactamente un worker consumer-group por cada uno de los ocho streams Redis (`ctr.p0` hasta `ctr.p7`); ningún otro proceso puede escribir en una partición que no es la suya, lo cual preserva el orden causal de los eventos dentro de cada episodio bajo concurrencia de hasta ocho episodios escribiendo simultáneamente. La tabla events en Postgres es única y no particionada físicamente —decisión justificable por la escala del piloto-1 donde se observaron aproximadamente 470 eventos en el dev seed—; el sharding vive estrictamente a nivel del bus Redis Streams como mecanismo de orden causal, no del almacenamiento. Cualquier futuro escalamiento que requiera particionamiento nativo de Postgres exigirá un nuevo ADR con migración explícita.

Una nota operativa adicional sobre el bootstrap del sistema en entornos Windows: los workers del servicio CTR utilizan `asyncio.add_signal_handler` para shutdown graceful, una función que el `ProactorEventLoop` de Windows no implementa. Sin el fix de envolver la llamada

en try/except NotImplementedError, los ocho workers crashean al arrancar y la persistencia del CTR queda detenida. El fix está aplicado en el código del worker de partición y documentado internamente como gotcha operativa.

A.2 Control de acceso por rol con políticas Casbin y RLS

El control de acceso a los recursos del sistema se implementa mediante 170 políticas Casbin sembradas en el servicio académico, organizadas como tuplas (rol, recurso, acción). Los cuatro roles del piloto son superadmin, docente_admin, docente y estudiante. El enforcement opera a nivel del rol y no del identificador de usuario individual, decisión arquitectónica con implicaciones académicas: el comportamiento del sistema frente a un estudiante específico no depende de quién sea ese estudiante sino del rol que tiene asignado en el contexto de la cohorte. La cifra 170 corresponde al recuento verificado el 9 de mayo de 2026 y evoluciona con el catálogo de recursos del sistema; los últimos bумeос corresponden al ADR-016 (14 políticas para tarea_practica_template), ADR-039 (8 políticas para byok_key) y ADR-041 (7 políticas para unidad). El recuento es auditable directamente contra el repositorio.

El esquema Casbin se complementa con Row-Level Security de Postgres a nivel de fila por tenant, formalizado en el ADR-001, que garantiza que consultas de una cohorte no pueden acceder a datos de otra cohorte aunque el código tenga un bug de filtrado, mediante la política SET LOCAL app.current_tenant aplicada por request. La combinación de control por rol (Casbin) y aislamiento por tenant (RLS) constituye la defensa en profundidad del sistema frente a accesos no autorizados.

A.3 Dualidad manifest-config en el versionado del prompt del tutor

El prompt del tutor se versiona mediante una dualidad de fuentes que constituye un gotcha de reproducibilidad documentado del sistema. El manifest declarativo ainnative-prompts/manifest.yaml especifica la versión activa del prompt con su estado, parseable por el módulo PromptLoader del servicio de gobernanza y expuesto a frontends mediante el endpoint GET /api/v1/active_configs. El tutor-service en runtime, sin embargo, no consulta el manifest sino una constante de configuración propia (default_prompt_version) que debe mantenerse sincronizada con el manifest. La alineación entre ambas fuentes es responsabilidad operacional cubierta por un test de consistencia (test_manifest_yaml_existe_y_se_parsea). En caso de desincronización accidental, la versión efectiva del prompt usada por el tutor queda registrada en cada evento del CTR

como prompt_system_hash, permitiendo auditoría retrospectiva contra el manifest declarado.

A.4 Constantes auditables del sistema

La Tabla A.1 sintetiza las constantes versionadas del sistema que sostienen la reproducibilidad del análisis. Cada una está identificada por su nombre en el código, su valor o estado al momento del cierre, y su función analítica.

Tabla A.1. Constantes auditables del sistema instrumental.

Constante	Valor o estado	Función
LABELER_VERSION	1.2.0 (vigente; previas: 1.0.0, 1.1.0)	Versión del etiquetador de eventos a niveles N1-N4
GUARDRAILS_CORPUS_VERSION	1.2.0 (vigente; previa: 1.1.0)	Versión del corpus de patrones de detección de adversarialidad
MIN_STUDENTS_FOR_QUARTILES	5	Umbral del gate de k-anonimato para endpoints cohortales
MIN_EPISODES_FOR_LONGITUDINAL	3	Umbral mínimo de episodios análogos para CII evolution longitudinal
NUM_PARTITIONS	8	Particiones del bus Redis Streams del CTR
ANOTACION_N1_WINDOW_SECONDS	120	Ventana temporal para override N1 de anotaciones tempranas
ANOTACION_N4_WINDOW_SECONDS	60	Ventana temporal para override N4 de anotaciones post-respuesta
GENESIS_HASH	"0" * 64	Ancla convencional del primer evento de cada episodio

Cada una de estas constantes es auditable contra el repositorio y queda referida en eventos del CTR o en clasificaciones según corresponda. Los hashes computados por el sistema (classifier_config_hash, guardrails_corpus_hash, chunks_used_hash, prompt_system_hash) operan como punteros criptográficos al estado del sistema en el momento en que cada evento se persistió, sosteniendo la auditabilidad intertemporal del análisis.

Agradecimientos

Los autores agradecen al equipo del PID UTN-FRM y Universidad Marcelino Champagnat sobre evaluación auténtica con IA generativa, particularmente a Daniela Carbonari (co-directora del PID), Bruno Roberti, Carlos Martínez, Claudia Naveda, Juan Sarmiento y Juan Robledo, por las discusiones que enriquecieron el aparato conceptual del modelo. Se reconoce el apoyo institucional de UTN-FRM y de UNSL.

Referencias

- [1] H. Arksey y L. O'Malley, "Scoping studies: towards a methodological framework," *International Journal of Social Research Methodology*, vol. 8, no. 1, pp. 19–32, 2005.
- [2] S. Bernstein, A. Rahman, N. Sharifi, A. Terbish y S. MacNeil, "Beyond the Benefits: A Systematic Review of the Harms and Consequences of Generative AI in Computing Education," en *Proc. 25th Koli Calling International Conference on Computing Education Research (Koli Calling '25)*, ACM, 2025, pp. 1–18. <https://doi.org/10.1145/3769994.3770036>
- [3] S. P. Chowdhury, V. Zouhar y M. Sachan, "AutoTutor meets large language models: a language model tutor with rich pedagogy and guardrails," en *Proc. 11th ACM Conf. Learning at Scale*, 2024, pp. 5–15.
- [4] A. Clark y D. Chalmers, "The extended mind," *Analysis*, vol. 58, no. 1, pp. 7–19, 1998.
- [5] J. Cohen, "A coefficient of agreement for nominal scales," *Educational and Psychological Measurement*, vol. 20, no. 1, pp. 37–46, 1960.
- [6] J. Cohen, *Statistical Power Analysis for the Behavioral Sciences*, 2.^a ed. Lawrence Erlbaum Associates, 1988.
- [7] P. Denny, J. Prather, B. A. Becker, J. Finnie-Ansley, A. Hellas, J. Leinonen, A. Luxton-Reilly, B. N. Reeves, E. A. Santos y S. Sarsa, "Computing education in the era of generative AI," *Communications of the ACM*, vol. 67, no. 2, pp. 56–67, 2024.
- [8] S. Elnaffar, F. Rashidi y A. Z. Abualkishik, "Teaching with AI: A Systematic Review of Chatbots, Generative Tools, and Tutoring Systems in Programming Education," *International Journal of Learning, Teaching and Educational Research*, vol. 25, no. 1, pp. 1–28, 2026. <https://doi.org/10.26803/ijlter.25.1.1>
- [9] N. Garrido y C. G. Neil, "Impact of Artificial Intelligence on the Learning Experience: A Systematic Literature Mapping," en *Simposio Argentino de Educación en Informática (SAEI 2025)*, 54° JAIIO, vol. 11, no. 8, SADIO, 2025, pp. 1–14. <http://sedici.unlp.edu.ar/handle/10915/190295>
- [10] E. Hutchins, *Cognition in the Wild*. Cambridge, MA: MIT Press, 1995.
- [11] M. R. Islam, A. M. Nitu, M. A. Marjan, M. P. Uddin, M. I. Afjal, M. A. Al Mamun y Z. Aung, "Enhancing tertiary students' programming skills with an explainable Educational Data Mining approach," *PLOS ONE*, vol. 19, no. 9, e0307536, 2024.
- [12] J. R. Landis y G. G. Koch, "The measurement of observer agreement for categorical data," *Biometrics*, vol. 33, no. 1, pp. 159–174, 1977.
- [13] D. Levac, H. Colquhoun y K. K. O'Brien, "Scoping studies: advancing the methodology," *Implementation Science*, vol. 5, p. 69, 2010.
- [14] J. McCambridge, J. Witton y D. R. Elbourne, "Systematic review of the Hawthorne effect: new concepts are needed to study research participation effects," *Journal of Clinical Epidemiology*, vol. 67, no. 3, pp. 267–277, 2014.
- [15] R. J. Mislevy, L. S. Steinberg y R. G. Almond, "Focus article: on the structure of educational assessments," *Measurement: Interdisciplinary Research and Perspectives*, vol. 1, no. 1, pp. 3–62, 2003.
- [16] S. Oviedo, D. Diaz y A. Otazú, "Perspectiva estudiantil sobre el uso de inteligencia artificial generativa en la enseñanza universitaria mediante el Modelo 3P de Biggs," *Universidad Nacional de San Juan, FCEFN, Instituto de Informática*, 2025. [En prensa]
- [17] N. Paez, D. Marcet y G. Cozzi, "Uso de la inteligencia artificial en la enseñanza de la programación: un estudio preliminar," en *Simposio Argentino de Educación en Informática (SAEI 2025)*, 54° JAIIO, SADIO, vol. 11, no. 8, 2025, pp. 74–79. <https://revistas.unlp.edu.ar/JAIIO/article/view/19934>
- [18] J. W. Pellegrino, N. Chudowsky y R. Glaser (eds.), *Knowing What Students Know: The Science and Design of Educational Assessment*. Washington, DC: National Academy Press, 2001.
- [19] J. Prather, J. Leinonen, N. Kiesler et al., "Beyond the Hype: A Comprehensive Review of Current Trends in Generative AI Research, Teaching Practices, and Tools," en *Proc. 2024 ITiCSE Working Group Reports*, ACM, 2024. arXiv:2412.14732
- [20] P. Rabardel, *Les hommes et les technologies: approche cognitive des instruments contemporains*. Paris: Armand Colin, 1995.
- [21] I. Reihanian, Y. Hou y Q. Sun, "From Pilots to Practices: A Scoping Review of GenAI-Enabled Personalization in Computer Science Education," *AI (MDPI)*, vol. 7, no. 1, p. 6, 2026. <https://doi.org/10.3390/ai7010006>
- [22] W. R. Shadish, T. D. Cook y D. T. Campbell, *Experimental and Quasi-Experimental Designs for Generalized Causal Inference*. Houghton Mifflin, 2002.
- [23] E. Soloway y J. C. Spohrer (eds.), *Studying the Novice Programmer*. Lawrence Erlbaum Associates, 1989.
- [24] K. Sunil y A. Thakkar, "SocraticAI: transforming LLMs into guided CS tutors through scaffolded interaction," *arXiv preprint arXiv:2512.03501*, 2025.
- [25] A. C. Tricco, E. Lillie, W. Zarin, K. K. O'Brien, H. Colquhoun, D. Levac et al., "PRISMA Extension for Scoping Reviews (PRISMA-ScR): checklist and explanation," *Annals of Internal Medicine*, vol. 169, no. 7, pp. 467–473, 2018.

[26] G. Türkmen, “The review of studies on explainable artificial intelligence in educational research: a systematic review from 2019 to present.”

Procedencia del documento

Esta versión del paper integra tres rondas sucesivas de consolidación sobre la base argumentativa y estructural del paper original ppcona.docx (Cortez & Garis, UTN-FRM + UNSL).

Primera ronda (2026-05-10): 10 decisiones académicas resueltas. Las 10 decisiones académicas que originalmente requerían resolución conjunta de los autores fueron consolidadas en dos pasadas sucesivas durante el 10 de mayo de 2026. La primera pasada resolvió los 6 markers relacionados con el umbral kappa intercoder y el protocolo muestral con $\kappa \geq 0,70$ conforme a Landis y Koch (1977), estructurado como Protocolo A (200 eventos estratificados, 50 por nivel cognitivo N1-N4, para validar el etiquetador) y Protocolo B (50 episodios cerrados distribuidos entre las tres categorías de apropiación, para validar el árbol de decisión); esta decisión queda formalizada en el ADR-046 del repositorio del proyecto con supersede parcial sobre los ADRs 027, 032, 044 y 045. La segunda pasada resolvió las 4 familias temáticas restantes: reconciliación 3 dimensiones / 5 coherencias en §4.5 con desdoblamiento de CCD en promedio y orphan ratio y de CII en estabilidad y evolución; mención única del proyecto “AI-Native N4” como nombre del sistema de software que materializa el modelo sin acoplar el modelo teórico al descriptor de producto; párrafo único al final de §5.2 que enumera las capacidades de plataforma con referencia a sus ADRs canónicos sin desarrollarlas (preserva el foco teórico del paper); y suavización de “analogía funcional” a “inspirado en” en la comparación del CTR con Caliper Analytics 1.2 y xAPI, con declaración del exporter conforme como agenda de extensión del sistema instrumental. Estas 10 decisiones fueron documentadas en ppconarev.md y se reflejaron simultáneamente en código (event_labeler_lexical.py, KappaRatingView.tsx, docs/limitaciones-declaradas.md) para preservar la coherencia paper $\leftrightarrow$ implementación.

Segunda ronda (2026-05-10): incorporación operacional. Una segunda ronda de consolidación incorporó las 8 recomendaciones de redacción derivadas del análisis de 30 distorsiones y omisiones del paper original frente al código del sistema instrumental, documentadas en papermod.md (mayo de 2026). Entre las contribuciones principales de esta ronda se encuentra el desarrollo del Apéndice A con cuatro sub-secciones sobre sharding del CTR, control de acceso por rol con Casbin y RLS, dualidad manifest-config en el versionado del prompt del tutor y constantes auditables del sistema (Tabla A.1), así como la reformulación de la garantía de reproducibilidad como propiedad del estado completo del

sistema en un tiempo determinado (Sección 7.2), incluyendo la declaración honesta de la deuda operacional del piloto-1 sobre 106 clasificaciones con LABELER_VERSION previo al bumpeo a v1.2.0.

Tercera ronda (2026-05-16): incorporación cognitiva. Una tercera ronda de consolidación incorporó siete contribuciones derivadas del análisis cognitivo externo documentado en informeSocra1.md (2026-05-16), planificadas en plan1Socra.md (2026-05-16) y reconciliadas con la rama operacional de 2026-05-10 según el reporte de divergencia comparacion.md (2026-05-16). Las siete contribuciones agregan precisión epistemológica y declaración honesta del alcance del trabajo: enunciación explícita de los tres marcos interpretativos de tercer orden MI1, MI2 y MI3 en §4.3; distinción en prosa académica entre CII evolución intra-episodio y CII evolución longitudinal en §4.5; declaración explícita de la operacionalización vigente CCD-piloto-1 versus la operacionalización conceptual completa CCD-conceptual con sus respectivos alcances de validación intercoder en Tabla 3; introducción del marcador léxico anti-reificación “perfil tipológico de apropiación X” en §4.4 alineado con el principio “no-etiquetado individual” del protocolo interpretativo; declaración del ratio prompt/(prompts+ejecuciones) como decisión de diseño del implementador sujeto a calibración empírica post-piloto-1 en la celda CT de Tabla 3; tematización de la asimetría entre el marco teórico de cognición distribuida (Hutchins, 1995; Clark y Chalmers, 1998) declarado y la operacionalización individual efectiva en §3; y posicionamiento epistemológico explícito proceso observable versus aprendizaje en sentido cognitivo estricto anclado en Pellegrino, Chudowsky y Glaser (2001) en §9. Estas siete contribuciones agregan precisión sin modificar los hallazgos empíricos del piloto ni la formalización del modelo N4 en sus cuatro niveles.

Sincronización con la tesis doctoral. Las siete contribuciones cognitivas de la tercera ronda fueron propagadas en prosa adaptada al registro extendido de la tesis doctoral del autor (tesis16mayo.docx, 2026-05-16). Cada inyección en la tesis está marcada con la fórmula “Actualización sincronizada con paper Cortez & Garis (revisión 2026-05-16, CSXX)” para trazabilidad explícita entre el paper publicable y el documento de tesis extendido.

Insumos consultados a lo largo de las tres rondas: paper original ppcona.docx; análisis de alineamiento paper vs implementación ppconarev.md (2026-05-10); análisis de distorsiones y omisiones papermod.md (2026-05-10); análisis cognitivo externo informeSocra1.md (2026-05-16); plan de acción derivado plan1Socra.md (2026-05-16); reporte de divergencia y merge comparacion.md (2026-05-16); estado del sistema instrumental audi2.md (2026-05-10); invariantes operativas

AI-NativeV3-main/CLAUDE.md. Cierre operativo: 2026-05-16.